Inteligência Artificial, Inovação e Transformação da Ciência

Uma perspectiva estatística: fundamentos, incerteza e soberania

Prof. Dr. Jodavid Ferreira
Departamento de Estatística · CCEN · Universidade Federal de Pernambuco

Mesa-redonda do IV Workshop de Divulgação Científica e Didáticas (IV WDCD)
15 de outubro de 2026 · Auditório do CCEN

A IA acelera respostas. Quem garante as perguntas?

Modelos geram código, resumem a literatura e acham padrões em segundos.

Mas quem garante a qualidade das perguntas, a validade das evidências e o rigor das decisões?

> **Tecnologia gera possibilidades; critérios estatísticos transformam possibilidades em ciência.**

A IA já está na ciência. Replicar ciência, nem tanto.

+26%

artigos com IA nas ciências naturais em um ano (≈ 80 mil em 2025)

6–9%

da produção científica já envolve IA, conforme a área (< 1% em 2010)

88%

das organizações usam IA em ao menos uma função (McKinsey, 2025)

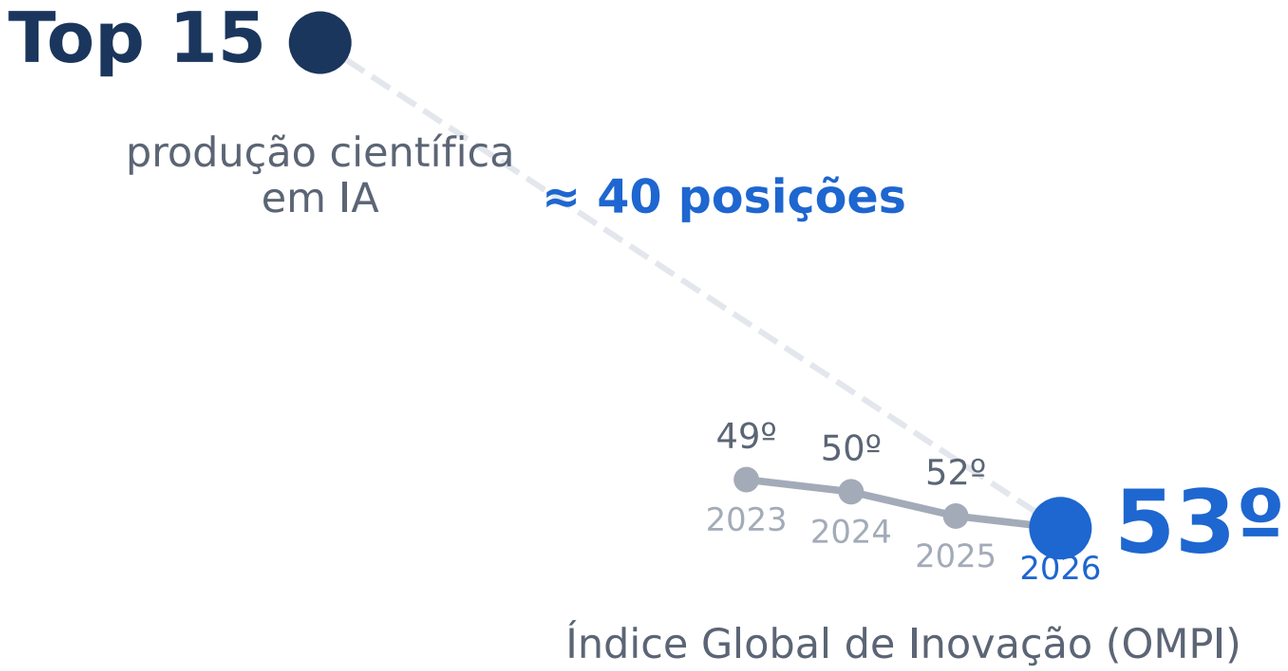
< 20%

de acerto dos modelos de fronteira ao tentar **replicar** artigos de astrofísica (ReplicationBench).

Gerar ficou barato. **Auditar** virou a competência decisiva.

Fonte: Stanford HAI, *AI Index Report 2026*; McKinsey, *State of AI 2025*.

Top 15 em ciência sobre IA. 53º em inovação.



Publicamos muito, mas convertemos pouco em produtos, patentes e empresas, e a posição **vem caindo**.

> **“Se o conhecimento não vira solução para a sociedade, vira autoelogio.”**

Fontes: CGEE (2025); OMPI, *Global Innovation Index* 2023–2026 (139 economias).

O Brasil compete onde há dados e problemas locais

1. Modelos de fronteira

escala de capital de outra ordem

2. Adaptação e especialização

SLMs, ajuste fino, dados e domínios locais

3. Aplicação estratégica

SUS · agro · clima · energia

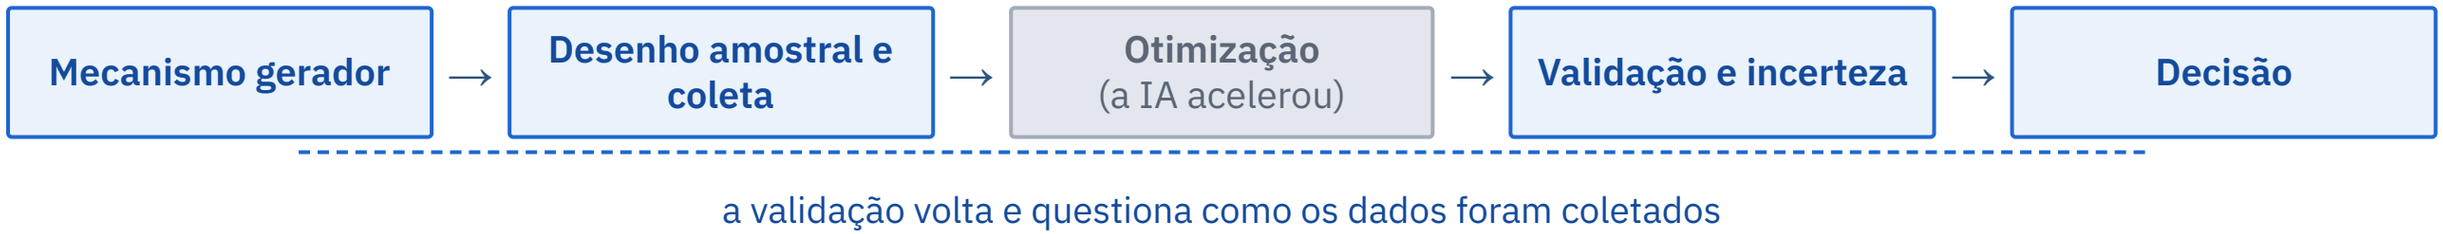
Nas camadas 2 e 3 estão problemas que ninguém lá fora vai resolver por nós.

A lição dos **genéricos**: capacidade nacional gera autonomia e poder de barganha.

> **É onde desenho amostral e validação local decidem.**

A IA acelerou uma etapa. A Estatística decide as outras.

Todo modelo, do mais simples ao maior LLM, aproxima o mecanismo gerador $P(X, Y)$ a partir de uma amostra finita: é inferência indutiva.



Sensibilidade: quanto muda com outra amostra?

População: o treino é a de aplicação?

Estrutura: padrão real ou espúrio?

Mais dados não corrigem dados ruins

250 mil

respostas *online* por semana superestimaram a vacinação contra Covid nos EUA em

17 p.p.

1 mil

respostas de uma **amostra probabilística**

acertou

$$\text{erro} = \underbrace{\rho_{R,Y}}_{\text{qualidade}} \times \underbrace{\sqrt{\frac{1-f}{f}}}_{\text{quantidade}} \times \underbrace{\sigma_Y}_{\text{dificuldade}}$$

Bradley et al. (2021), *Nature*; Meng (2018), *Annals of Applied Statistics*.

Com mais parâmetros que dados, o erro volta a cair

Clássico ($n > p$): uma solução.

$$\widehat{\beta} = \left(X^\top X \right)^{-1} X^\top y$$

Moderno ($p \gg n$): infinitas soluções; a regularização escolhe uma.

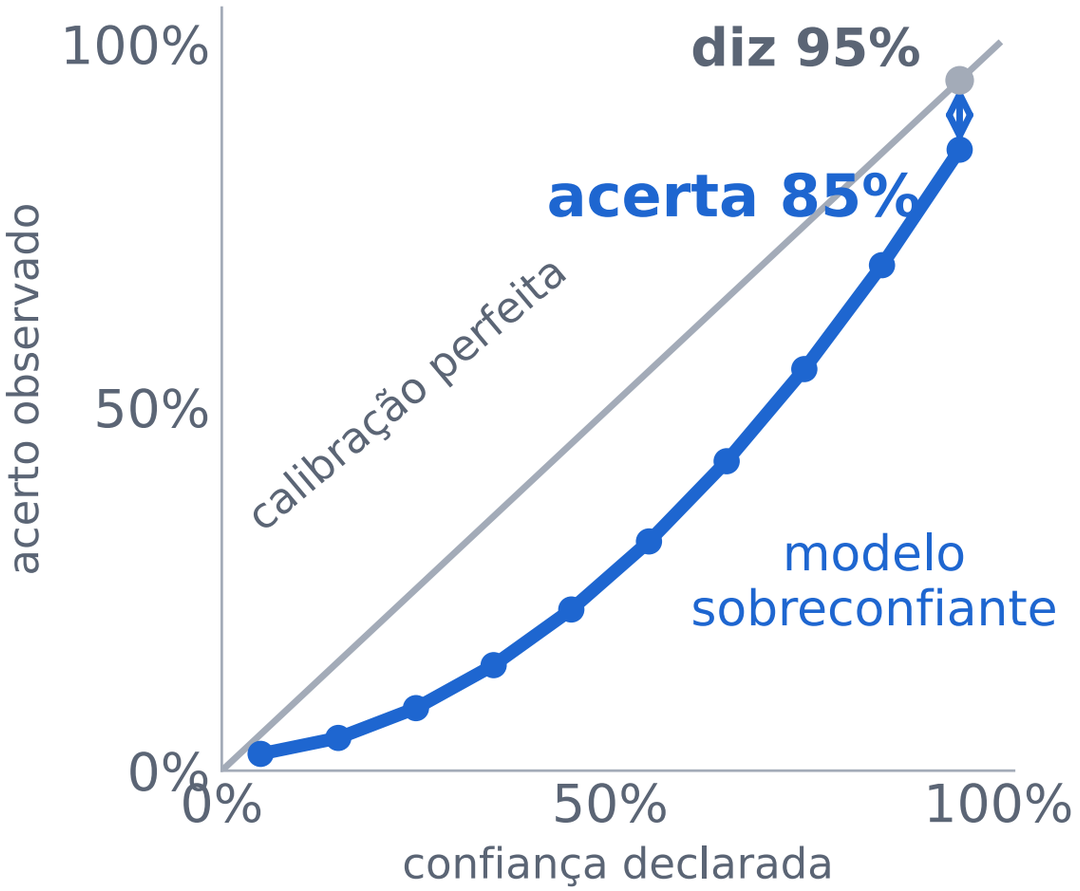
$$\widehat{\beta}_{\text{ridge}} = \left(X^\top X + \lambda I \right)^{-1} X^\top y$$



> **O desafio é escolher, entre infinitas soluções, a que generaliza.**

Belkin et al. (2019); Hastie et al. (2022).

Diz 95%, acerta 85%: fluência não é calibração



Calibrado é quem, ao dizer “90%”, acerta 90% das vezes.

Redes profundas modernas tendem a ser **sobreconfiantes** (Guo et al., 2017).

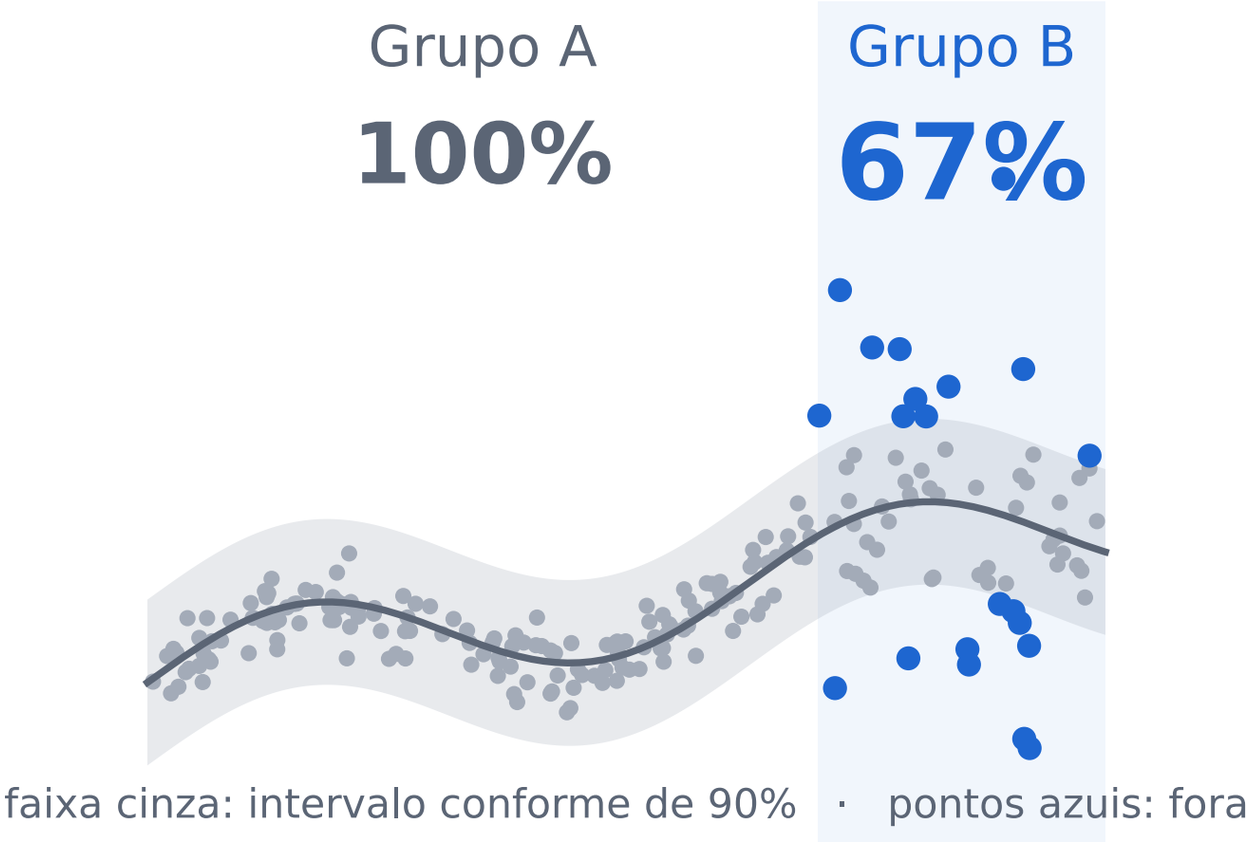
> **Confiança em texto fluente não é probabilidade, até ser verificada.**

Na média, 90% de cobertura. No grupo B, 67%.

A **predição conforme** dá a qualquer modelo intervalos com cobertura mínima garantida em amostra finita:

$$P(Y_{n+1} \in C(X_{n+1})) \geq 1 - \alpha$$

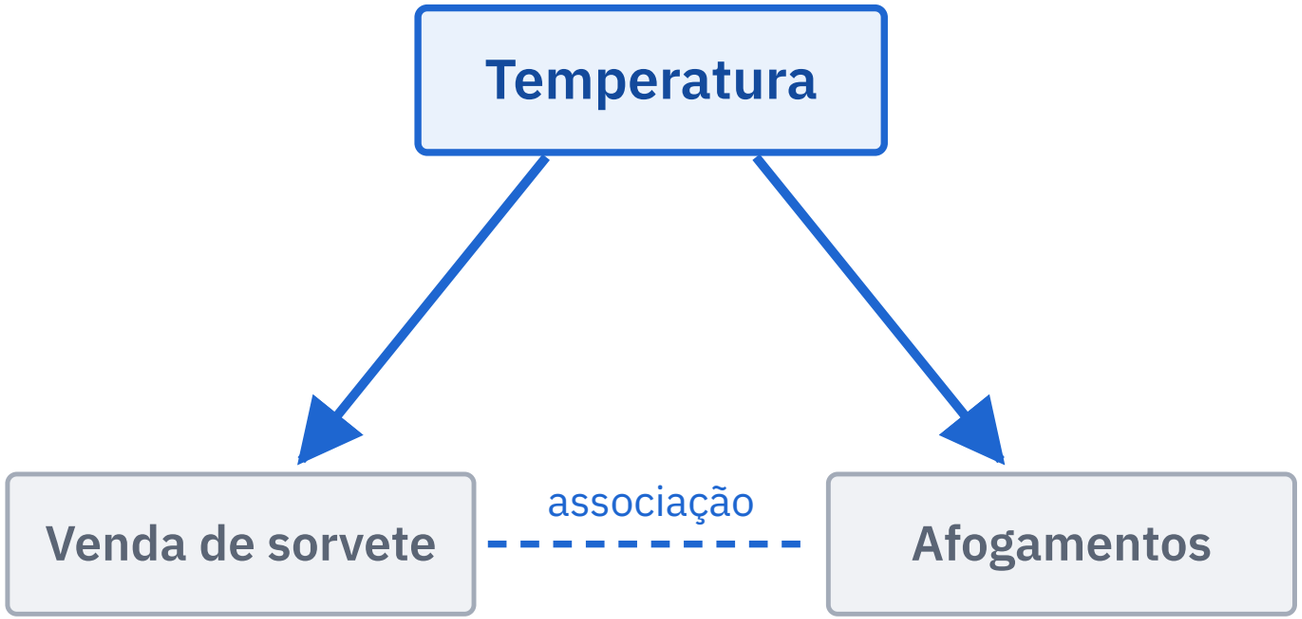
Exige permutabilidade. A garantia é **marginal**: vale na média, não em cada grupo.



faixa cinza: intervalo conforme de 90% · pontos azuis: fora

Média boa esconde subgrupo ruim: a auditoria tem de ser estratificada.

Prever não é intervir



proibir sorvete não reduz afogamentos

A escada de Pearl:

1. **Associação** $P(\, y \mid x \,)$: o que observamos e usamos para predizer.
2. **Intervenção** $P(\, y \mid do\,(\, x \,)\,)$: o que acontece quando definimos $X = x$.
3. **Contrafactual** Y_x: o que teria acontecido se X tivesse assumido outro valor.

Sem desenho ou suposições causais, dados observacionais não identificam efeitos, **não importa o tamanho do modelo**.

> **Prever quem vai adoecer não diz qual tratamento funciona.**

Quatro perguntas antes de confiar em um modelo

1 **Bate um modelo simples?**

Em 71 estudos clínicos, o ML não superou, em média, a regressão logística (Christodoulou et al., 2019).

2 **Funciona em outro hospital, outra cidade, outro equipamento?**

Modelo de pneumonia em raio-X aprendeu a reconhecer *o hospital*, não a doença (Zech et al., 2018).

3 **É estável a pequenas perturbações?**

Modelos de Covid usavam marcas de texto na imagem (DeGrave et al., 2021).

4 **Sabe dizer quando não sabe?**

Intervalos, calibração, abstenção.

> **Não "o modelo acerta?", mas: em que condições, para quem, com que margem de erro?**

Uma conferência, 29 mil artigos: volume não é ciência

≈ 29 mil

submissões à trilha principal da AAAI-26, quase o dobro de 2025

AAAI; OpenReview (2026)

6,5–16,9%

do texto de revisões em conferências de IA (2023–24) modificado por LLMs, estimado por **máxima verossimilhança**

Liang et al. (2024), ICML

> **A universidade precisa valorizar profundidade, reprodutibilidade e impacto real.**

O código roda. O resultado pode ser falso.

Aceleração legítima: AlphaFold (Nobel 2024), simulação, Monte Carlo.

Riscos: equações erradas, citações inventadas, ilusão de entendimento.

97%

de acurácia aparente não prova nada.

Os erros mais comuns são **silenciosos**:

- **Vazamento:** padronizar, imputar ou selecionar variáveis antes de separar treino e teste.
- **Dependência ignorada:** mesmo paciente ou série temporal tratados como i.i.d.
- **Sobreajuste por tentativas:** o jardim dos caminhos que se bifurcam.

Kapoor & Narayanan (2023): vazamento em centenas de artigos de 17 áreas.

> **O computador não vê esses erros; a Estatística vê. A responsabilidade autoral não se transfere.**

O gargalo não é o hardware: é o dado e quem sabe lê-lo

“Comprar hardware é o passo mais fácil; o desafio é usá-lo de forma produtiva para o país.”

O que está saturado

Usuário de *prompt* pronto e de tutorial, sem base para auditar.

O perfil disputado

Fundamentos de probabilidade, **rigor de desenho** e capacidade de formular problemas reais.

> **Bibliotecas mudam a cada dois anos; verossimilhança, amostragem e causalidade, não.**

O que queremos que o estudante aprenda?

Avaliar o percurso, não só o produto

Tarefa antiga

"Ajuste uma regressão linear múltipla e calcule o intervalo de confiança."

A IA faz em segundos.

Tarefa adaptada

"Gere duas modelagens com IA. Aponte onde as hipóteses foram violadas, corrija e **defenda oralmente** sua escolha."

Defender uma escolha diante de uma banca é a prova oral da vida real.

Outras ideias: erros plantados numa análise feita por IA; bases do IBGE e DATASUS; arguição curta por **sorteio** em turmas grandes.

Quanto maior o impacto, maior a exigência

Viés e equidade , Privacidade (LGPD, art. 11), Acesso equitativo, Autoria e integridade

	Risco baixo	Risco moderado	Risco alto
Atividade	Brainstorming, revisão de estilo	Análise exploratória, código assistido	**Atribuir notas, selecionar bolsistas, diagnóstico**
Governança	Uso livre com leitura crítica	Validação e declaração de uso	**Supervisão humana, explicabilidade, direito a recurso**
Pergunta	Faz sentido?	O estimador é válido?	**Quem responde pelo erro?**

> **O AI Act europeu classifica IA para admissão e avaliação educacional como alto risco.**

Reg. (UE) 2024/1689, Anexo III. No Brasil, o PL 2.338/2023 também classifica por risco.

Para continuar a reflexão

> *"A Inteligência Artificial pode acelerar a velocidade das nossas respostas.* ***Mas é a Estatística que garante a solidez das nossas perguntas e a calibração das nossas incertezas.***"

Não seremos consumidores passivos de tecnologia: seremos **construtores críticos da inovação, com rigor**.

Muito obrigado!

Prof. Dr. Jodavid Ferreira

Departamento de Estatística - CCEN/UFPE

jodavid.ferreira@ufpe.br | http://jodavid.github.io

Feito com auxílio de IA, usando o modelo Claude Opus 5.5 (Anthropic), mas a responsabilidade pelo conteúdo, pelos dados e pelas referências é do autor.

Referências

Angelopoulos, A. N.; Bates, S. (2023). Conformal prediction: a gentle introduction. *Foundations and Trends in ML*, 16(4).

Belkin, M.; Hsu, D.; Ma, S.; Mandal, S. (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off. *PNAS*, 116(32), 15849–15854.

Bradley, V. C. et al. (2021). Unrepresentative big surveys significantly overestimated US vaccine uptake. *Nature*, 600, 695–700.

Breiman, L. (2001). Statistical modeling: the two cultures. *Statistical Science*, 16(3), 199–231.

CGEE (2025). *O Panorama Brasileiro da Ciência, Tecnologia e Inovação em Inteligência Artificial*.

Christodoulou, E. et al. (2019). No performance benefit of machine learning over logistic regression for clinical prediction models. *J. Clin. Epidemiol.*, 110, 12–22.

DeGrave, A. J.; Janizek, J. D.; Lee, S.-I. (2021). AI for radiographic COVID-19 detection selects shortcuts over signal. *Nature Machine Intelligence*, 3, 610–619.

Guo, C.; Pleiss, G.; Sun, Y.; Weinberger, K. Q. (2017). On calibration of modern neural networks. *ICML*.

Hastie, T.; Montanari, A.; Rosset, S.; Tibshirani, R. (2022). Surprises in high-dimensional ridgeless least squares interpolation. *Annals of Statistics*, 50(2), 949–986.

Kapoor, S.; Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804.

Liang, W. et al. (2024). Monitoring AI-modified content at scale: ChatGPT and AI conference peer reviews. *ICML*.

McKinsey & Company (2025). *The State of AI in 2025*.

Meng, X.-L. (2018). Statistical paradises and paradoxes in big data (I). *Annals of Applied Statistics*, 12(2), 685–726.

Pearl, J. (2009). *Causality: Models, Reasoning and Inference*. Cambridge University Press.

Soares, A. (2026). A nova corrida da IA nas empresas e universidades brasileiras. Podcast *IA Sob Controle*, ep. 288.

Stanford HAI (2026). *The 2026 AI Index Report*, cap. 5 (Science).

União Europeia (2024). Regulamento (UE) 2024/1689 (AI Act), Anexo III.

WIPO/OMPI (2025, 2026). *Global Innovation Index*.

Zech, J. R. et al. (2018). Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs. *PLoS Medicine*, 15(11), e1002683.